

Attribution under Disagreement：分辨 Agent 差異中的 Harness 與 Model 來源

一、題目

有些使用者在用 coding agent 且無自行檢查時會遇到以下情況：（1）目前 agent 卡住，切到另一個重跑同 task（2）高風險改動前，找另一個 agent 覆核（3）試用新 agent 時，拿舊任務測試比較。三種情境下，必須判斷差異來自 harness 還是 model，判錯等於浪費錢、時間。本研究接續自己在 xAI Proposal 產出的結果，比較使用者在這三個場景中的歸因準確度。

（一）設計取捨

- 1. 藉自己 xAI Proposal 的 6 configs × 20 tasks 已產出的 factorial trace 當 ground truth；N=1-3 但每 trial 都有明確正解。
- 2. 不只整理正確率，也記信心與理由，分辨「答對」與「猜對」。

二、呈現方式

PPT 錄影。

三、實作步驟

- 1. 自 xAI factorial trace 挑 20 對 contrastive pair，含 harness-only、model-only、interaction、noise。
- 2. 做 pair viewer：並列輸出，下方四選一歸因 + 信心 1-5 + 一句理由，揭露後比對 ground truth。
- 3. 跑 20 對共 20 trial。
- 4. 紀錄整體正確率、四類混淆矩陣、信心曲線，理由。

四、研究方法

（一）Contrastive Pair 類型

Pair 類型	配對方式	xAI Ground Truth
Harness-only	同 model、不同 harness	harness 主效應
Model-only	同 harness、不同 model	model 主效應
Interaction	factorial 中顯著異常組合	交互項
Noise	同配置重跑	隨機誤差

（二）三個觸發場景的 case 配比

- 1. 切換後場景：8 對，task 偏卡關／失敗案例。
- 2. 高風險覆核場景：8 對，task 偏 destructive 或 prod-relevant 改動。
- 3. Onboarding 場景：4 對，task 偏受試者曾做過的熟悉度測試。

（三）指標

整體歸因正確率、四類混淆矩陣、信心曲線、理由線索（看了哪些 cue 做判斷）。

五、預期結果

1. RQ1：三場景合計歸因正確率多高？
2. RQ2：哪類差異最常被誤歸？預期 harness 差異常被誤歸到 model 例如「XX 模型較強」
3. RQ3：信心與正確率是否校正？哪個觸發場景的信心過剩最嚴重？
4. RQ4：若歸因不準，介面該做的是「揭露更多 trace」還是「直接給歸因 label」？